

ETL E INGESTÃO DE DADOS COM PYTHON

PROJETO DE INGESTÃO, TRATAMENTO, INTEGRAÇÃO E DISPONIBILIZAÇÃO DE DADOS UTILIZANDO PYTHON.


ARQUITETURA RAW → TRUSTED → DELIVERY.

ATENDE AOS REQUISITOS ACADÊMICOS SEM USO DE SPARK OU DUCKDB.



ARQUITETURA

- Fontes → RAW (PostgreSQL) → TRUSTED (Parquet) → DELIVERY (Parquet + PostgreSQL)
- Tratamentos e integrações realizados exclusivamente em Python/Pandas.



PIPELINE



Ingestão RAW

Leitura das bases originais e carga na camada RAW (PostgreSQL).



1 Limpeza e padronização

Tratamento de tipos, valores nulos, padronização de textos e datas.



3 União das bases

Consolidação das bases de reclamações e complementares.



4 Normalização de CNPJ

Padronização do CNPJ (apenas números, 14 dígitos).



5 JOIN com Enquadramento

Integração com base de enquadramento (por CNPJ).



6 JOIN com Glassdoor

Integração com bases do Glassdoor (por CNPJ ou nome).



7 Geração Delivery

Geração da camada DELIVERY (Parquet) e carga da tabela final no PostgreSQL.



8 Validação

Validações de qualidade, contagens e verificações de integridade.



REGRAS DE TRATAMENTO



A → 1

- Conversão de tipos



- Tratamento de nulos



- Remoção de duplicidades

1,23
→
1.23

- Conversão decimal

Abc
→
abc

- Padronização de textos



- JOIN via `pandas.merge()`

RESULTADO FINAL

- Dados **Trusted** em Parquet




- **Dataset final** em Parquet



- Tabela **delivery.reclamacoes_glassdoor_final** no PostgreSQL



- Pipeline automatizada via **run_pipeline.py**



CONCLUSÃO



- **SOLUÇÃO ESCALÁVEL** BASEADA EM PYTHON, POSTGRESQL E **PARQUET**.



- **CUMPRE OS REQUISITOS** UTILIZANDO PROCESSAMENTO EXCLUSIVAMENTE EM **PYTHON**.

